

scikit-learn 概述

1

什么是Scikit-learn ?

Scikit-learn是基于NumPy、 SciPy和 Matplotlib的开源Python机器学习包,它封装了一系列数据预处理、机器学习算法、模型选择等工具,是数据分析师首选的机器学习工具包。

自2007年发布以来, scikit-learn已经成为Python重要的机器学习库了, scikit-learn简称sklearn, 支持包括分类, 回归, 降维和聚类四大机器学习算法。还包括了特征提取, 数据处理和模型评估三大模块。

The logo for scikit-learn, featuring the text "scikit-learn" in a white, lowercase, sans-serif font on a blue background. Below it, the text "Machine Learning in Python" is written in a smaller, italicized, white, lowercase, sans-serif font.


scikit-learn

Machine Learning in Python

scikit-learn 概述

2

什么是Scikit-learn ?



scikit-learn 概述

3

API学习手册

- <https://scikit-learn.org.cn/>
- <https://www.scikitlearn.com.cn/>



CDA scikit-learn 中文社区


安装 用户指南 API 案例 更多 ▾ 交流群

scikit-learn

Machine Learning in Python

入门 0.23版本的发布要点 GitHub

交流微信群二维码



sklearn

Search docs

sklearn 中文文档

- 目录
- 作者
- 整理
- 校招巴士

安装 scikit-learn

- 1. 监督学习
 - 1.0 监督学习
 - 1.1. 广义线性模型
 - 1.2. 线性和二次判别分析
 - 1.3. 内核岭回归
 - 1.4. 支持向量机
 - 1.5. 随机梯度下降
 - 1.6. 最近邻
 - 1.7. 高斯过程
 - 1.8. 交叉分解

Next »

Docs » sklearn 中文文档

sklearn 简介

scikit-learn 是基于 Python 语言的机器学习工具

- 简单高效的数据挖掘和数据分析工具
- 可供大家在各种环境中重复使用
- 建立在 NumPy, SciPy 和 matplotlib 上
- 开源, 可商业使用 - BSD许可证

[点击下载OpenCV最新中文官方文档pdf版](#)

目录

- 安装 scikit-learn
- 用户指南
 - 1. 监督学习
 - 1.1. 广义线性模型
 - 1.2. 线性和二次判别分析
 - 1.3. 内核岭回归
 - 1.4. 支持向量机
 - 1.5. 随机梯度下降

scikit-learn 概述

4

scikit-learn 的特点

数据丰富： 内置丰富的数据集，比如：泰坦尼克，鸢尾花等，数据不再发愁

功能丰富： 使用sklearn能够进行数据的预处理、特征工程、数据集切分、模型评估等工作


建模无敌： 用户通过sklearn可以实现各种监督和非监督学习的模型

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition.

Algorithms: SVM, nearest neighbors, random forest, and more...




Examples

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.

Algorithms: SVR, nearest neighbors, random forest, and more...



Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, and more...




Examples

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency

Algorithms: k-Means, feature selection, non-negative matrix factorization, and more...




Examples

Model selection

Comparing, validating and choosing parameters and models.

Applications: Improved accuracy via parameter tuning

Algorithms: grid search, cross validation, metrics, and more...




Examples

Preprocessing

Feature extraction and normalization.

Applications: Transforming input data such as text for use with machine learning algorithms.

Algorithms: preprocessing, feature extraction, and more...



Examples

scikit-learn主要用法

5

符号标记

`X_train`

训练数据.

`X_test`

测试数据.

`X`

完整数据.

|

`y_train`

训练集标签.

|

`y_test`

测试集标签.

`Y`

数据标签.

scikit-learn主要用法

6

基本建模流程

导入工具包

```
from sklearn import datasets, preprocessing
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score
```

scikit-learn主要用法

7

基本建模流程

加载数据

- Scikit-learn支持以NumPy的arrays对象、Pandas对象、SciPy的稀疏矩阵及其他可转换为数值型arrays的数据结构作为其输入，前提是数据必须是数值型的。
- sklearn.datasets模块提供了一系列加载和获取著名数据集如鸢尾花、波士顿房价、Olivetti人脸、MNIST数据集等的工具，也包括了一些toy data如S型数据等的生成工具

```
from sklearn.datasets import load_iris  
  
iris = load_iris()  
X = iris.data  
y = iris.target
```

scikit-learn主要用法

8

基本建模流程

数据划分

```
from sklearn.model_selection import train_test_split  
  
X_train, X_test, y_train, y_test = train_test_split(X, y,  
                                                    random_state=12, stratify=y, test_size=0.3)
```



- 将完整数据集的70%作为训练集，30%作为测试集，并使得测试集和训练集中各类别数据的比例与原始数据集比例一致（stratify分层策略），另外可通过设置 `shuffle=True` 提前打乱数据

scikit-learn主要用法

9

基本建模流程

数据预处理

- 使用Scikit-learn进行数据标准化

```
from sklearn.preprocessing import StandardScaler
```

- 构建转换器实例

```
scaler = StandardScaler()
```

- 拟合及转换

```
scaler.fit_transform(X_train)
```

Z-Score标准化

$$x^* = \frac{x - \mu}{\sigma}$$

$$\sigma^2 = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu)^2$$
$$\mu = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$

处理后的数据均值为0，方差为1

scikit-learn主要用法

10

基本建模流程

监督学习算法 – 回归

```
from sklearn.linear_model import LinearRegression
```

➤ 构建模型实例

```
lr = LinearRegression(normalize=True)
```

➤ 训练模型

```
lr.fit(X_train, y_train)
```

➤ 作出预测

```
y_pred = lr.predict(X_test)
```

scikit-learn主要用法

11

基本建模流程

监督学习算法 – 分类

```
from sklearn.tree import DecisionTreeClassifier
clf = DecisionTreeClassifier(max_depth=5)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)
y_prob = clf.predict_proba(X_test)
```

- 使用决策树分类算法解决二分类问题, `y_prob` 为每个样本预测为 “0” 和 “1” 类的概率

scikit-learn主要用法

12

基本建模流程

监督学习算法

- 逻辑回归 `linear_model.LogisticRegression`
- 支持向量机 `svm.SVC`
- 朴素贝叶斯 `naive_bayes.GaussianNB`
- K近邻 `neighbors.NearestNeighbors`
- 线性回归 `LinearRegression`

无监督学习算法

- DBSCAN `cluster.DBSCAN`
- 层次聚类 `cluster.AgglomerativeClustering`
- 谱聚类 `cluster.SpectralClustering`

scikit-learn主要用法

13

基本建模流程

评价指标

sklearn.metrics模块包含了一系列用于评价模型的评分函数、损失函数以及成对数据的距离度量函数。

```
from sklearn.metrics import accuracy_score  
accuracy_score(y_true, y_pred)
```

对于测试集而言, y_test即是y_true, 大部分函数都必须包含真实值y_true和预测值y_pred

scikit-learn主要用法

14

基本建模流程

评价指标-回归模型

`metrics.mean_absolute_error()` | 平均绝对误差MAE
`metrics.mean_squared_error()` | 均方误差MSE
`metrics.r2_score()` | 决定系数 R^2 .

评价指标-分类模型

`metrics.accuracy_score()` | 正 确 率 .
`metrics.precision_score()` | 各类精确率.
`metrics.f1_score()` | F1 值 .
`metrics.log_loss()` | 对数损失或交叉熵损失.
`metrics.confusion_matrix` | 混淆矩阵.
`metrics.classification_report` | 含多种评价的分类报告.