

使用K-最近邻算法构建鸢尾花分类模型

一 任务描述

鸢尾花（Iris）数据集是机器学习中一个经典的数据集。假设有一名植物学爱好者收集了150朵鸢尾花的测量数据：花瓣的长度和宽度以及花萼的长度和宽度，这些花已经鉴定为属于Setosa、Versicolor和Virginica三个品种之一。

本任务的主要工作内容包括：

- 1、使用Pandas和Matplotlib可视化并观察数据；
- 2、将数据集随机拆分为训练集（train set）和测试集（test set）；
- 3、构建一个机器学习分类模型（K-最近邻算法）并评估其准确性（Accuracy）。

二 任务目标

1. 掌握机器学习的基本概念，如样本、特征、训练集和测试集、泛化能力、模型评估、模型的准确性（Accuracy）等。 **重点**
2. 熟悉使用Scikit-learn构建机器学习模型的基本过程。
重点
3. 熟悉K-最近邻算法（KNN算法）的思想。
重点
4. 掌握数据集拆分函数、训练拟合函数、模型评估函数的使用。
重点

三 任务环境

- 操作系统：Windows 10、Ubuntu18.04
- 工具软件：Anaconda3 2019、Python3.7
- 硬件环境：无特殊要求
- 依赖库列表

matplotlib	3.3.4
numpy	1.19.5
pandas	1.1.5
scikit-learn	0.24.2

四 任务分析

因为学习数据中已知鸢尾花的品种（即数据的标签），所以这是一个监督学习，另外模型的用途是预测新的测量数据的品种，因此这是一个分类（Classification）问题。单个数据点（一朵鸢尾花的测量数据）的预期输出是这朵花的品种（标签）。

本任务涉及以下几个环节：

- a) 认识数据、观察数据（可视化）
- b) 将数据拆分为训练集与测试集
- c) 构建模型：K最近邻算法
- d) 训练模型
- e) 评估模型

五 任务实施

5.1 加载Iris数据集、查看数据内容

鸢尾花数据集是Scikit-learn自带的数据集，我们通过load_iris()函数来加载。

```
from sklearn.datasets import load_iris

# 鸢尾花数据集是sklearn自带数据集，使用load_iris函数加载
iris = load_iris()

print(iris.keys()) # 查看数据集的组成部分
```

实验结果：

```
dict_keys(['data', 'target', 'frame', 'target_names', 'DESCR', 'feature_names',
'filename'])
```

通过keys()函数可以查看数据集有哪些Keys（即数据项），依次查看其数据项。

查看data数据（鸢尾花测量数据）：

```
data = iris.data # 150朵鸢尾花的特征数据
print(data.shape)# 共150行，4列
print(data) # 每一列分别是花萼长度、花萼宽度，花瓣长度，花瓣宽度
```

查看其它数据内容：

```
# 每一行数据所属的种类，即数据的标签，(0-Setosa,1-versicolor,2-Virginica)
target = iris.target
print(target)

target_names = iris.target_names # 三种鸢尾花的名称
print(target_names)

feature_names = iris.feature_names # 四个特征的名称
print(feature_names)
```

实验结果：


```


ax1.set_ylabel(feature_names[1], fontsize=15) # y轴标签
ax1.legend(fontsize=14)

ax2 = fig.add_subplot(1, 2, 2) # 添加第二个子图，可视化花瓣长宽数据
ax2.set_title('Petal data ', fontsize=18)
for i in range(3): # 分类画出花瓣数据的散点图
    ax2.scatter(data[:,2][target==i], data[:,3][target==i],
    label=target_names[i])

ax2.set_xlabel(feature_names[2], fontsize=15)
ax2.set_ylabel(feature_names[3], fontsize=15)
plt.legend(fontsize=14)
plt.show()

```

可视化结果：



通过上面的数据可视化可以直观地看出，利用花瓣（Petal）和花萼（Sepal）的测量数据基本可以将三个类别区分开，这说明机器学习算法很可能可以学会区分它们。

5.3 将数据集拆分为训练集和测试集



```

from sklearn.model_selection import train_test_split

# 使用train_test_split函数将数据集拆分为训练集和测试集
# 特征数据和标签都需要进行拆分（参数1、2）
# test_size 指定测试集的比例（默认0.25，即25%的数据作为测试集，其余作为训练集）
# random_state 指定随机数种子，确保每次运行结果相同
# 通常用大写X_来表示数据，小写y_来表示标签
# 返回值依次是训练集数据、测试集数据、训练集标签、测试集标签
X_train, X_test, y_train, y_test = train_test_split(data, target,
test_size=0.25, random_state=0)
print(X_train.shape) # 训练集尺寸
print(X_test.shape) # 测试集尺寸

```

结果如下：

```
(112, 4)
(38, 4)
```

Scikit-learn 中的 `train_test_split` 函数可以按照指定的比例将数据集随机拆分为训练集和测试集。根据经验，通常会用75%的数据作为训练集，25%作为测试集。

5.4 使用K-最近邻算法构建分类模型并评估成绩

回顾：K-最近邻算法的思想

物以类聚——近朱者赤，近墨者黑。判断一个事物的类型，只要分析离它最近的几个事物就行（比如，判断一个人的类型，只要看和他（她）关系最亲密的几个人就行）。KNN算法通过判断一个数据点最近的 K 个邻居（比如K= 3 或K= 5 ）的大多数类型，来判断该数据点的类型。

```
from sklearn.neighbors import KNeighborsClassifier

# 创建KNN分类器，参数n_neighbors=3表示用最近的3个邻居来判断1个数据点的类型
model = KNeighborsClassifier(n_neighbors=3)

# 拟合数据，即：将训练数据和标签交给模型去学习
model.fit(X_train, y_train)

# 使用score方法在测试集上评估模型成绩
score = model.score(X_test, y_test)
print('Test set score: %0.2f' %score)
```

结果如下：

```
Test set score: 0.97
```

模型评估的成绩为0.97%，即分类预测的准确率为97%。

模型评估的目的是检验模型是否可用（即模型的性能是否达到应用要求）。模型评估需要用到测试集，我们可以对测试数据中的每朵鸢尾花进行预测，并将预测结果与标签（已知的品种）进行对比，从而计算出模型的准确率（accuracy）。在Scikit-learn中，使用模型的score方法计算分类准确率。

5.5 使用模型进行预测

机器学习的最终目的是建立符合要求的模型，应用到新数据的预测中。在本案例中，我们可以预测测试集前10个数据的品种，也可以预测一个新测量数据的品种。

```
import numpy as np

# 1、预测测试集中前10条数据的种类
y_pred = model.predict(X_test[:10])
print('y_pred:', y_pred)
print('y_true:', y_test[:10]) # 打印实际标签与预测结果作对比

# 2、假设我们新测量了一朵鸢尾花的四个特征值，用模型预测它的种类
X_new = np.array([[5, 2.9, 1, 0.2]])
prediction = model.predict(X_new) # 使用predict方法进行预测
print('prediction:', prediction) # 输出预测结果（标签）
print('prediction names:', target_names[prediction]) # 输出预测的种类名称
```

结果如下：

```
y_pred: [2 1 0 2 0 2 0 1 1 1]
y_true: [2 1 0 2 0 2 0 1 1 1]
prediction : [0]
prediction names: ['setosa']
```

六 任务总结

本实验主要介绍K-最近邻算法构建鸢尾花分类模型的主要流程：

1. 加载数据集
2. 拆分数据集为训练集和测试集
3. 构建k最近邻模型
4. 模型评估和预测

七 任务知识测试

1、关于机器学习中数据的特征，下面说法正确的是：（单选）（ ）

- A、特征是指数据的条数
- B、特征是指数据的属性
- C、特征是指数据集的形状
- D、特征是指测试集的比例

2、scikit-learn中拆分数据集所用的函数是：（单选）（ ）

- A、fit
- B、score
- C、train_test_split
- D、predict

3、K-最近邻算法的核心思想是：（单选）（ ）

- A、根据训练集中最近的K个数据点来对新数据点做出预测
- B、根据测试集中最近的K个数据点来对新数据点做出预测
- C、在训练集中循环K次，寻找最近的一个邻居
- D、在测试集中循环K次，寻找最近的一个邻居

4、鸢尾花（Iris）数据集中，样本的特征数是多少？（单选）（ ）

- A、150
- B、112
- C、4
- D、2

5、在构建鸢尾花分类模型过程中，涉及到的流程有：（多选）（ ）

- A、加载数据、观察数据
- B、将数据集拆分为训练集和测试集
- C、创建模型、拟合数据
- D、模型评估