

基于K-最近邻算法构建红酒分类模型

一 任务描述

Wine红酒数据集是机器学习中一个经典的分类数据集，它是意大利同一地区种植的葡萄酒化学分析的结果，这些葡萄酒来自三个不同的品种。数据集中含有178个样本，分别属于三个已知品种，每个样本含有13个特征（即13个化学成分值）。任务是根据已有的数据集建立分类模型，预测新的葡萄酒数据的类别。

任务内容包括：

- 1、加载红酒数据并使用Matplotlib将数据可视化
- 2、将数据集随机拆分为训练集和测试集
- 3、构建K-最近邻算法分类模型并评估其准确性

二 任务目标

- | | |
|----------------------------------|-----|
| 1. 利用K-NN算法实现红酒分类模型。 | 重点 |
| 2. 进一步熟悉Scikit-learn构建机器学习模型的过程。 | 重难点 |
| 3. 熟练掌握K-最近邻算法（KNN算法）的原理。 | 重难点 |
| 4. 掌握数据集拆分函数、训练拟合函数、模型评估函数的使用。 | 重点 |


三 任务环境

- 操作系统：Windows 10、Ubuntu18.04
- 工具软件：Anaconda3 2019、Python3.7
- 硬件环境：无特殊要求
- 依赖库列表

```
matplotlib 3.3.4
numpy 1.19.5
pandas 1.1.5
scikit-learn 0.24.2
mglearn 0.1.9
```

四 任务分析

红酒数据集包括178条红酒样本数据，每个样本有13个特征值（13个化学成分测量值），同时还给出了这178条红酒样本对应的品种（共三个种类——class0、class1、class2）。我们需要根据这些数据建立红酒分类模型，并能够预测新的样本数据的品种。因为样本数据中已经包含了对应的红酒品种（即数据的标签），所以这是一个监督学习中的分类（Classification）问题。



#	特征名称	特征说明
0	alcohol	酒精
1	malic_acid	苹果酸
2	ash	灰分
3	alcalinity_of_ash	灰分的碱度
4	magnesium	镁
5	total_phenols	总酚
6	flavanoids	黄酮类化合物
7	nonflavanoid_phenols	非黄酮类酚类
8	proanthocyanins	原花色素
9	color_intensity	颜色强度
10	hue	色调
11	od280/od315_of_diluted_wines	稀释葡萄酒od280/od315
12	proline	脯氨酸

本任务涉及以下几个环节：

- 加载、查看红酒数据集
- 数据可视化
- 将数据拆分为训练集与测试集
- 构建模型并评估、预测

五 任务实施

5.1 加载、查看红酒数据集

红酒数据集是Scikit-learn自带的数据集，我们通过load_wine ()函数来加载。

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# 加载wine数据集
wine = load_wine()
print(wine.keys()) # 查看数据集构成

print('shape of data:', wine.data.shape) # 查看样本数据的形状
print('shape of target:', wine.target.shape) # 查看标签数据的形状
print('target_names:', wine.target_names) # 查看红酒类别名称
print('feature_names:', wine.feature_names) # 样本的十三个特征名称
```

输出结果：

```
dict_keys(['data', 'target', 'frame', 'target_names', 'DESCR', 'feature_names'])
shape of data: (178, 13)
shape of target: (178,)
target_names: ['class_0' 'class_1' 'class_2']
feature_names: ['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash',
'magnesium', 'total_phenols', 'flavanoids', 'nonflavanoid_phenols',
'proanthocyanins', 'color_intensity', 'hue', 'od280/od315_of_diluted_wines',
'proline']
```

通过keys()函数可以查看数据集中有哪些Keys（即数据项），依次查看其数据项。

使用pandas查看数据：

```
# 使用pandas查看样本数据
df = pd.DataFrame(wine.data, columns=wine.feature_names)
df
```

输出结果：

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280/od3
0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	0.28	2.29	5.64	1.04	
1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	0.26	1.28	4.38	1.05	
2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	0.30	2.81	5.68	1.03	
3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	0.24	2.18	7.80	0.86	
4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	0.39	1.82	4.32	1.04	
...	...	...	...	...	...	...	...	...	...	...	...	...
173	13.71	5.65	2.45	20.5	95.0	1.68	0.61	0.52	1.06	7.70	0.64	
174	13.40	3.91	2.48	23.0	102.0	1.80	0.75	0.43	1.41	7.30	0.70	
175	13.27	4.28	2.26	20.0	120.0	1.59	0.69	0.43	1.35	10.20	0.59	
176	13.17	2.59	2.37	20.0	120.0	1.65	0.68	0.53	1.46	9.30	0.60	
177	14.13	4.10	2.74	24.5	96.0	2.05	0.76	0.56	1.35	9.20	0.61	

178 rows x 13 columns

5.2 数据集可视化

红酒数据样本有13个特征，任意2个都可以形成1幅散点图，这里我们随机选2个特征，生成10幅散点图，查看数据分布情况。

```
import random

# wine数据集可视化
fig = plt.figure(figsize=(16,25)) # 定义画板尺寸

data = wine.data # 样本数据
target = wine.target # 数据标签
target_names = wine.target_names # 标签名称
feature_names = wine.feature_names # 特征名称


# 任选2个特征生成散点图，共生成10个子图
for i in range(10):
    random_feature = random.sample(range(13), 2) # 任选2个特征
    ax = fig.add_subplot(5, 2, i+1) # 添加子图（5行2列，第i+1个子图）
```

```
for j in range(3): # 依次显示每个种类（共3类）的数据
    ax.scatter(data[:,random_feature[0]][target==j],
               data[:,random_feature[1]][target==j], label=target_names[0])

    ax.set_xlabel(feature_names[random_feature[0]], fontsize=15)
    ax.set_ylabel(feature_names[random_feature[1]], fontsize=15)
    ax.legend()

plt.show()
```

显示结果：



红酒数据集有13个特征，可以形成一个13维的空间，为了方便显示，我们只是在2维空间里（每次随机选2个特征作为X轴和y轴）对数据进行简单可视化。

可视化的目的是更好地了解数据。从随机生成的散点图中可以发现，有些特征组合在2维空间上就已经比较容易分类（如图2和图4），有些特征组合在二维空间上的重叠度较高，不容易分类，需要考虑更多维度。

5.3 将数据集拆分为训练集和测试集

Scikit-learn提供了train_test_split函数将红酒数据集（形状为（178, 13））随机拆分为训练集和测试集，参数除了样本数据和数据标签外，还包括：

- test_size参数：测试集比例（默认为0.25）。
- random_state参数：随机数种子（为了固定随机结果，便于数据重现。如果不指定，每次拆分结果都不同）。

```
# 拆分数据集
# test_size=0.25(25%作为测试集，75%作为训练集)
# random_state=0(随机数种子，固定随机结果，便于数据重现)
X_train, X_test, y_train, y_test = train_test_split(data, target,
test_size=0.25, random_state=0)
print(X_train.shape, X_test.shape)
```

输出结果：

```
(133, 13) (45, 13)
```

5.4 构建K-NN模型，评估并预测

```
# 构建模型
model = KNeighborsClassifier(n_neighbors=3)
model.fit(X_train, y_train) # 拟合训练数据

# 评估模型
score = model.score(X_test, y_test)
print('Score:{:.2f}'.format(score))

# 预测红酒种类
y_pred = model.predict(X_test[:5]) # 预测测试集前五个样本的品种
print(y_pred) # 打印预测结果
print(y_test[:5]) # 打印实际品种
```

输出结果：

```
Score:0.73
[0 1 1 0 1]
[0 2 1 0 1]
```

六 任务总结

- 本实验介绍了使用KNN模型对红酒数据集进行分类预测。
- 机器学习的基本流程为准备数据集→数据集处理→创建模型→模型评估预测。

七 任务知识测试

- 1、下列表述能体现K-NN算法思想的是：（多选）（ ）
 - A、近朱者赤、近墨者黑
 - B、物以类聚、人以群分
 - C、根据K个邻居的类型判断测试点的类型
- 2、K-NN算法的功能包括：（多选）（ ）
 - A、分类
 - B、回归
 - C、聚类
 - D、降维
- 3、关于K-NN算法中的“K”，表述正确的是：（多选）（ ）
 - A、算法中考虑的邻居个数
 - B、样本的种类数量
 - C、一般选择3或5
- 4、本实验中，红酒数据集的尺寸（shape）是：（单选）（ ）
 - A、(150,3)
 - B、(178,13)
 - C、(178,3)
 - D、(150,13)