

使用线性回归构建波士顿房价预测模型

一 任务描述

波士顿房价数据集统计了波士顿地区506套房屋的特征以及它们的成交价格，这些特征包括周边犯罪率、房间数量、房屋是否靠河、交通便利性、空气质量、房产税、社区师生比例（即教育水平）、周边低收入人口比例等。我们的任务是根据上述数据集建立模型，能够预测房屋价格及其走势。

本任务涉及的主要实践内容：

- 1、线性回归预测模型的构建
- 2、模型的预测与评估
- 3、使用matplotlib绘制房价预测曲线

二 任务目标

1. 利用线性回归算法（linearRegression）构建波士顿房价预测模型。
2. 掌握线性回归的原理及使用。
3. 掌握岭回归（Rigde）及Lasso回归的调用。

重难点
重点

三 任务环境

- 操作系统：Windows 10、Ubuntu18.04
- 工具软件：Anaconda3 2019、Python3.7
- 硬件环境：无特殊要求
- 依赖库列表

matplotlib	3.3.4
numpy	1.19.5
pandas	1.1.5
scikit-learn	0.24.2
mglearn	0.1.9

四 任务分析

任务的输出（房价）是个连续值，因此这是一个回归问题，算法的目的是寻找房屋的特征数据和房价之间的规律（即回归函数）。

本任务涉及以下几个环节：

- a) 加载、查看波士顿房价数据集

- b) 将数据拆分为训练集与测试集
- d) 构建线性回归模型，拟合训练数据、
- e) 预测房价
- f) 评估模型
- g) 利用Matplotlib生成房价预测走势曲线

五 任务实施

5.1 加载、查看波士顿房价数据集

```
from sklearn.datasets import load_boston # 引入load_boston函数
from sklearn.model_selection import train_test_split # 引入数据集拆分函数
from sklearn.linear_model import LinearRegression # 引入LinearRegression类

# 加载boston数据集
boston = load_boston()
print(boston.keys()) # 查看boston数据集的组成
print(boston.data.shape) # 查看输入数据的形状-（506套房屋数据，每条数据包含13个特征值）
print(boston.target.shape) # 查看标签数组的形状-（506套房屋的成交价格）
print(boston.feature_names) # 查看特征名称（房屋的13个特征名称）
```

输出结果：

```
dict_keys(['data', 'target', 'feature_names', 'DESCR', 'filename'])
(506, 13)
(506,)
['CRIM' 'ZN' 'INDUS' 'CHAS' 'NOX' 'RM' 'AGE' 'DIS' 'RAD' 'TAX' 'PTRATIO'
 'B' 'LSTAT']
```

通过keys()函数可以查看数据集中有哪些Keys（即数据项），依次查看其数据项。

通过观察，我们可以看到，波士顿数据集的特征数据（data数组）包含506套房屋的数据，有“犯罪率”、“房间数量”、“房屋年龄”、“师生比”等13个特征值，这506套房屋对应的成交价格（即数据的标签）存放在target数组中。我们的任务是基于这506套房屋的交易数据建立一个回归模型，能够对波士顿地区的房价数据进行预测。（即寻找房屋的特征与房价之间的线性规律）

5.2 数据集拆分

```
# 将data和target随机拆分为训练集和测试集（test_size=0.25代表25%的数据作为测试集，75%为训练集）
X_train, X_test, y_train, y_test = train_test_split(boston.data, boston.target,
                                                    test_size=0.25,
                                                    random_state=0)
print(X_train.shape, X_test.shape) # 查看拆分结果
print(y_train.shape, y_test.shape)
```

输出结果：

```
(379, 13) (127, 13)
(379,) (127,) # 379+127=506
```

通过scikit-learn中的train_test_split函数将数据集随机拆分成训练集与测试集。注意掌握train_test_split函数的参数含义及返回值定义。另外，在机器学习中，一般用大写X表示输入数据（即特征数据），小写的y表示输出数据（即标签）。

5.3 创建线性回归模型，拟合训练数据

```
# 创建模型
model = LinearRegression()

# 拟合训练数据（即将特征数据和标签数据交给模型去训练）
model.fit(X_train, y_train)

# 注意：上面两步也可以合并写成这样
# model = LinearRegression().fit(X_train, y_train)
```

注意：Scikit-learn中所有模型的使用都是同样的过程。因此，学习机器学习最重要的是在熟悉模型的思想原理、参数及优缺点的前提下，根据任务选择不同的模型来实现。

5.4 使用模型预测房屋价格

```
import numpy as np

# 预测测试集的输出（即测试集中房屋的房价）
y_pred = model.predict(X_test)
print(y_pred[:10]) # 预测前10套房屋的价格

# 将预测结果与实际价格做对比
print('\n预测价格：', np.round(y_pred[:10])) # np.round()-四舍五入取整
print('实际价格：', np.round(y_test[:10]))
```

输出结果：

```
[10.92635315 34.36995076 30.80593435 43.33525222 19.107834 18.8326957
 22.14409312 20.47370887 36.85094144 17.84471519]

预测价格： [11. 34. 31. 43. 19. 19. 22. 20. 37. 18.]
实际价格： [16. 44. 24. 50. 20. 20. 17. 22. 42. 13.]
```

在Scikit-learn中，模型的预测使用predict方法，但仅看预测结果我们无法得知模型的准确率，所以还需要进行模型的准确性评估。另外，我们还会使用Matplotlib绘图，将房价预测曲线与实际房价曲线做对比，结果一目了然。（Matplotlib是机器学习中不可或缺的可视化利器）

5.5 评估模型

```
# 使用score方法评估模型的成绩
train_score = model.score(X_train, y_train) # 获得模型在训练集上的成绩
test_score = model.score(X_test, y_test) # 获得模型在测试集上的成绩
print('Train set score:', train_score)
print('Test set score:', test_score)
```

输出结果:

```
Train set score: 0.7697699488741149
Test set score: 0.6354638433202116
```

Scikit-learn中，模型的评估使用score方法，参数1为输入特征数据，参数2为标签（即实际房价）。本任务没有对数据进行预处理，经过预处理后模型的准确性还会有所提高。数据预处理（缩放）会有一个专门的章节讲述，届时我们会做个对比。


5.6 使用Matplotlib生成房价预测走势曲线

```
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 4)) # 设置画板尺寸
plt.rcParams['font.sans-serif'] = 'FangSong' # 设置中文字体
plt.title('波士顿房价预测曲线与实际曲线对比图', fontsize=15)
x = range(len(y_test)) # x轴数据

plt.plot(x, y_test, color='r', label='实际价格') # 实际价格曲线
plt.plot(x, y_pred, color='g', ls='--', label='预测价格') # 预测价格曲线
plt.legend(fontsize=12, loc=1) # 显示图例
plt.show()
```

显示结果:



5.7 使用岭回归 (Ridge) 建模

LinearRegression (标准线性回归)、Ridge、Lasso都在sklearn.linear_model模块中。Ridge和Lasso回归是在标准线性回归函数中加入正则化项,以降低过拟合现象。

```
from sklearn.datasets import load_boston # 引入load_boston函数
from sklearn.model_selection import train_test_split # 引入数据集拆分函数
from sklearn.linear_model import Ridge # 引入Ridge模型

# 加载boston数据集
boston = load_boston()

# 拆分数据集
X_train, X_test, y_train, y_test = train_test_split(boston.data, boston.target,
                                                    test_size=0.25,
                                                    random_state=66)

# 构建模型
model = Ridge(alpha=10).fit(X_train, y_train)

# 评估模型
train_score = model.score(X_train, y_train)
test_score = model.score(X_test, y_test)

print('train score:{:.2f}'.format(train_score), '\ntest score:
{:.2f}'.format(test_score))
```

输出结果:

```
train score:0.70
test score:0.81
```

六 任务总结

- 回归问题解决的预测数据是连续的,房价的走势是连续数据,所以适合用回归的方式进行预测。
- 同学可以根据实验结果,对比线性回归和岭回归对波士顿房价预测结果的准确性。

七 任务知识测试

1、波士顿房价数据集的尺寸(shape)是:(单选) ()

- A、(569,10)
- B、(150,4)
- C、(506,13)

2、波士顿房价预测模型属于:(单选) ()

- A、分类模型
- B、回归模型
- C、聚类模型

D、降维模型

3、岭回归和Lasso回归是在标准线性回归的函数中加入了：（单选）（ ）

A、权重系数

B、偏移量

C、正则化项

4、关于线性模型的表述，正确的是：（多选）（ ）

A、既能处理分类问题，也能处理回归问题

B、只能处理回归问题

C、线性是指变量之间具有一次方函数关系

D、Lasso回归不属于线性模型