

使用逻辑回归构建肿瘤预测模型

一 任务描述

乳腺癌数据集包括569个样本，每个样本有30个特征值（病灶特征数据），每个样本都属于恶性（0）或良性（1）两个类别之一，要求使用逻辑回归（LR）算法建立预测模型，实现准确预测新的病灶数据的类型（恶性或良性）。

样本特征数据为病灶影像的测量数据，部分特征如下：

特征名称	特征说明	特征名称	特征说明
radius	半径，即病灶中心点离边界的平均距离。	compactness	密实度
texture	纹理，灰度值的标准偏差。	concavity	凹度，凹陷轮廓的严重程度。
perimeter	周长，即病灶的大小。	concave points	凹点，凹陷轮廓的数量。
area	面积，也是反映病灶大小的一个指标。	symmetry	对称性。
smoothness	平滑度，即半径的变化幅度。	fractal demension	分形维度。

本任务的主要实践内容：

- 1、逻辑回归-肿瘤预测模型的构建、预测及评估
- 2、逻辑回归-鸢尾花（Iris）分类模型的实现

二 任务目标

1. 利用逻辑回归算法（LogisticRegression）构建肿瘤预测模型。
2. 掌握逻辑回归的原理及使用。
3. 掌握sigmoid函数的含义。
4. 利用逻辑回归实现多分类案例（鸢尾花案例-3分类）

重难点
重难点

三 任务环境

- 操作系统：Windows 10、Ubuntu18.04
- 工具软件：Anaconda3 2019、Python3.7
- 硬件环境：无特殊要求
- 依赖库列表

```
matplotlib 3.3.4
numpy 1.19.5
pandas 1.1.5
scikit-learn 0.24.2
mglearn 0.1.9
```

四 任务分析


```
1 1 0 1 0 1 0 1 1 1 0 1 1 1 1 1 1 1 0 0 0 1 1 1 1 1 1 1 1 1 1 0 0 1 0 0
0 1 0 0 1 1 1 1 1 0 1 1 1 1 1 0 1 1 1 0 1 1 0 0 1 1 1 1 1 1 0 1 1 1 1 1
1 0 1 1 1 1 1 0 1 1 0 1 1 1 1 1 1 1 1 1 1 1 1 0 1 0 0 1 0 1 1 1 1 1 0 1 1
0 1 0 1 1 0 1 0 1 1 1 1 1 1 1 1 1 0 0 1 1 1 1 1 1 0 1 1 1 1 1 1 1 1 1 0 1
1 1 1 1 1 1 0 1 0 1 1 0 1 1 1 1 1 0 0 1 0 1 0 1 1 1 1 1 0 1 1 0 1 0 1 0 0
1 1 1 0 1 1 1 1 1 1 1 1 1 1 1 1 0 1 0 0 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1 1 1 1 1 1 0 0 0 0 0 0 0 1]
```

5.2 拆分数数据集

```
from sklearn.model_selection import train_test_split

# 随机拆分数数据集
# X_train 训练集
# X_test 测试集
# y_train 训练集标签（即训练集数据对应的类别）
# y_test 测试集标签（即测试集数据对应的类别）
# test_size 测试集比例
# random_state 随机状态（设置为固定值可以锁定拆分结果，用于数据复现）
X_train, X_test, y_train, y_test = train_test_split(cancer.data, cancer.target,
                                                    test_size=0.25,
                                                    random_state=0)
# 查看拆分情况
print(X_train.shape, X_test.shape)
print(y_train.shape, y_test.shape)
```

输出结果：

```
(426, 30) (143, 30)
(426,) (143,)
```

5.3 构建模型、评估

```
from sklearn.linear_model import LogisticRegression

# 采用默认参数创建LR模型，并拟合训练数据
model = LogisticRegression().fit(X_train, y_train)

# 评估模型在训练集和测试集上的成绩
score_train = model.score(X_train, y_train)
score_test = model.score(X_test, y_test)
print(score_train, score_test)
```

输出结果：

```
0.9553990610328639 0.958041958041958
```

5.4 在测试集上预测结果，并输出预测概率

这里我们预测测试集中的前三个样本，输出预测结果（0-恶性，1-良性），并输出0和1对应的概率值。

```
# 预测结果（0-恶性，1-良性）
y_pred = model.predict(X_test[:3]) # 预测测试集前三个样本
print(y_pred)

# 输出预测的概率值（0和1的概率值）
y_pred_proba = model.predict_proba(X_test[:3]) # 预测测试集前三个样本
print(y_pred_proba)
```

输出结果：

```
[0 1 1]
[[0.99284545 0.00715455]
 [0.0332907  0.9667093 ]
 [0.00271258 0.99728742]] # 该样本属于0的概率为0.002，属于1的概率为0.997，所以判断为类别1
```

强调：逻辑回归算法计算样本属于每个类别的概率值（即可能性），取概率值最大的类别作为预测结果。

5.5 扩展练习——基于逻辑回归实现鸢尾花分类（多分类问题）

```
from sklearn.datasets import load_iris

# 加载Iris数据集
iris = load_iris()

# 数据集拆分
X_train, X_test, y_train, y_test = train_test_split(iris.data, iris.target,
                                                    test_size=0.25,
                                                    random_state=0)

# 创建LR模型
# model = LogisticRegression().fit(X_train, y_train) # 0.9821428571428571
# 0.9736842105263158
# 优化模型参数，提升模型性能（C正则化系数，penalty正则化类型l1 or l2）
model = LogisticRegression(C=10, penalty='l2').fit(X_train, y_train) #
0.9910714285714286 0.9736842105263158

# 评估模型成绩
score_train = model.score(X_train, y_train)
score_test = model.score(X_test, y_test)
print(score_train, score_test)

# 预测鸢尾花种类并与实际种类做对比（前十个样本）
y_pred = model.predict(X_test)
print('预测类别: ', y_pred[:10])
print('实际类别: ', y_test[:10])
```

输出结果：

```
0.9821428571428571 0.9736842105263158
```

```
预测类别: [2 1 0 2 0 2 0 1 1 1]
```

```
实际类别: [2 1 0 2 0 2 0 1 1 1]
```

优化参数，提升模型性能：

```
model = LogisticRegression(C=10, penalty='l2').fit(X_train, y_train) #
```

```
0.9910714285714286 0.9736842105263158
```

优化后结果为：

```
0.9910714285714286 0.9736842105263158
```

```
预测类别: [2 1 0 2 0 2 0 1 1 1]
```

```
实际类别: [2 1 0 2 0 2 0 1 1 1]
```

六 任务总结

- 逻辑回归本质上是线性回归，只是在特征到结果的映射中加入了一层函数映射，即先把特征线性求和，然后使用函数 $g(z)$ 将最为假设函数来预测。 $g(z)$ 可以将连续值映射到0到1之间。
- 逻辑回归常用来解决分类问题，也可以用来预测事件发生的概率。
- 逻辑回归不仅可以用于二分类问题，也可以用于多分类问题。

七 任务知识测试

- 1、逻辑回归（LR）解决的问题是：（单选）（ ）
A、分类
B、回归
C、聚类
D、降维
- 2、本实验用到的乳腺癌数据集的尺寸（shape）是：（单选）（ ）
A、（506,30）
B、（569,30）
C、（506,13）
D、（569,13）
- 3、逻辑回归所有的分类函数是：（单选）（ ）
A、 $\tanh$
B、 relu
C、 sigmoid
D、 $\sin$

4、关于逻辑回归的表述，正确的是：（多选）（ ）

- A、既能处理分类问题，也能处理回归问题
- B、只能处理回归问题
- C、只能处理分类问题
- D、既能处理二分类问题，也能处理多分类问题