

# 基于多种聚类算法实现鸢尾花聚类

## 一 任务描述

聚类（Clustering）属于无监督学习的一种，聚类算法是根据数据的内在特征，将数据进行分组（即“内聚成类”），本任务我们通过实现鸢尾花聚类案例掌握Scikit-learn中多种经典的聚类算法（K-Means、MeanShift、Birch）的使用。

本任务的主要工作内容：

- 1、K-均值聚类实践
- 2、均值漂移聚类实践
- 3、Birch聚类实践

## 二 任务目标

1. 熟练掌握K-均值聚类算法的调用，了解其参数的含义
2. 掌握均值漂移（MeanShift）算法的使用
3. 掌握层次聚类（Birch）算法的使用
4. 用上述聚类模型对比实现鸢尾花聚类

## 三 任务环境

- 操作系统：Windows 10、Ubuntu18.04
- 工具软件：Anaconda3 2019、Python3.7
- 硬件环境：无特殊要求
- 依赖库列表

|              |        |
|--------------|--------|
| matplotlib   | 3.3.4  |
| pandas       | 1.1.5  |
| scikit-learn | 0.24.2 |

## 四 任务分析

本实验使用鸢尾花（iris）数据集的花瓣长度（petal length）和花瓣宽度（petal width）两个特征，共150行。运用不同模型对这两个特征数据进行聚类，并将聚类结果与实际的类别标签做对比（使用Matplotlib）。

本任务涉及以下几个环节：

- a) 获取鸢尾花花瓣特征数据

- b) 分别使用K-Means、MeanShift、Birch等算法进行聚类
- d) 获得聚类结果标签
- e) 评估聚类模型成绩
- f) 使用Matplotlib将聚类结果可视化

## 五 任务实施

### 5.1 获取花瓣特征数据（花瓣长度、花瓣宽度）

```
from sklearn.datasets import load_iris
from sklearn.cluster import KMeans, MeanShift, Birch, DBSCAN
from sklearn.metrics import adjusted_rand_score # 聚类模型评估工具
from IPython.display import display
import matplotlib.pyplot as plt
import pandas as pd

# 加载鸢尾花数（Iris）数据集
iris = load_iris()
data = iris.data[:,2:] # 取后两列（花瓣长、宽）作为特征数据
target = iris.target # 标签数据
feature_names = iris.feature_names[2:] # 后两列的名字
df = pd.DataFrame(data, columns=feature_names)# 创建数据框
display(df) # 显示数据集
```

显示结果：

|     | petal length (cm) | petal width (cm) |
|-----|-------------------|------------------|
| 0   | 1.4               | 0.2              |
| 1   | 1.4               | 0.2              |
| 2   | 1.3               | 0.2              |
| 3   | 1.5               | 0.2              |
| 4   | 1.4               | 0.2              |
| ... | ...               | ...              |
| 145 | 5.2               | 2.3              |
| 146 | 5.0               | 1.9              |
| 147 | 5.2               | 2.0              |
| 148 | 5.4               | 2.3              |
| 149 | 5.1               | 1.8              |

150 rows × 2 columns

## 5.2 使用多种聚类算法，并评估成绩

```
# 注意：聚类模型的评估使用sklearn.metrics.adjusted_rand_score函数
# 参数1-实际类别标签
# 参数2-聚类结果标签
# 调用聚类算法

model = KMeans(3).fit(data) # K-均值聚类

# model = Meanshift().fit(data) # 均值漂移聚类
# model = Birch().fit(data) # Birch聚类
c_target = model.labels_ # 聚类结果标签

# 使用adjusted_rand_score函数来评估聚类效果
# 参数1-实际类别标签
# 参数2-聚类结果标签
print('accuracy: ', adjusted_rand_score(target, c_target))
```

结果如下：

```
accuracy:  0.8856970310281228
```

## 5.3 使用Matplotlib将聚类结果可视化

将聚类结果与样本的实际分类可视化，直观对比聚类效果。


```
# 定义画板尺寸
fig = plt.figure(figsize=(15, 5))

# 画第一幅子图——实际类别标签
ax1 = fig.add_subplot(1, 2, 1)
ax1.set_title('Real ')
ax1.scatter(data[:,0], data[:,1], c=target)

# 画第二幅子图——聚类结果
ax2 = fig.add_subplot(1, 2, 2)
ax2.set_title('Clustering ')
ax2.scatter(data[:,0], data[:,1], c=c_target)

# 显示图形
plt.show()
```

显示结果：



注：两幅图中从上到下依次为3种鸢尾花的特征分布（颜色随机），左图是实际情况，右图是聚类结果，可以看到聚类算法比较准确地还原了实际类别。

## 5.4 任务扩展

本实验中我们使用的是鸢尾花的花瓣特征数据，有兴趣的同学可以尝试一下使用花萼数据进行上述聚类过程。

## 六 任务总结

本实验使用K-Means、Birch、MeanShift等多种聚类算法对鸢尾花数据进行聚类，并且将最终聚类的结果可视化。同学可以对比不同的聚类方法的准确率。

## 七 任务知识测试

- 1、本实验中，我们使用的聚类算法有：（多选）（ ）
  - A、KMeans
  - B、KNN
  - C、MeanShift
  - D、Birch
- 2、Birch聚类属于：（单选）（ ）
  - A、均值聚类
  - B、层次聚类
  - C、密度聚类
- 3、本实验中用到的聚类评估函数为：（单选）（ ）
  - A、adjusted\_rand\_score
  - B、score
  - C、r2\_score
- 4、下列哪种聚类算法可以不指定聚类数量参数？（多选）（ ）

A、 KMeans

B、 Birch

C、 MeanShift