

使用交叉验证评估模型

一 任务描述

交叉验证 (cross-validation) 是一种常用的模型评估方法，在交叉验证中，数据被多次划分（多个训练集和测试集），在多个训练集和测试集上训练模型并评估。相对于单次划分训练集和测试集来说，交叉验证能够更准确、更全面地评估模型的性能。

本任务的主要实践内容：

- 1、应用k-折交叉验证 (k-fold)
- 2、应用留一法交叉验证 (leave-one-out)
- 3、应用打乱划分交叉验证 (shuffle-split)

二 任务目标

- a) 理解并熟练掌握k-折交叉验证的使用
- b) 理解并掌握留一法交叉验证的使用及适用场景
- c) 理解并掌握打乱划分交叉验证的使用及适用场景

三 任务环境

- 操作系统：Windows10、Ubuntu18.04
- 工具软件：Anaconda3 2019、Python3.7
- 硬件环境：无特殊要求
- 依赖库列表

```
scikit-learn 0.24.2
```

四 任务分析

任务数据集采用鸢尾花 (iris) 数据集，使用逻辑回归和K-最近邻创建分类模型，分别练习三种交叉验证方法的使用。

本任务涉及以下环节：

- a) k-折交叉验证评估模型
- b) 留一法交叉验证评估模型
- c) 打乱划分交叉验证评估模型

五 任务实施

步骤1、使用K-折交叉验证评估模型

```
from sklearn.model_selection import cross_val_score # 交叉验证函数
from sklearn.datasets import load_iris
from sklearn.linear_model import LogisticRegression

iris = load_iris() # 加载iris数据集
model = LogisticRegression() # 创建逻辑回归模型

# 交叉验证，参数依次为：模型、数据、数据标签、cv（即折数K）
scores = cross_val_score(model, iris.data, iris.target, cv=3) # cv=3，即3折交叉，输出3个评估成绩
print(scores) # 每次的评估成绩（数组）
print(scores.mean()) # 计算平均成绩
```

输出结果：

```
[0.98 0.96 0.98]
0.9733333333333333
```

说明：

1. Scikit-learn交叉验证函数为**cross_val_score**，参数cv表示划分的折数k，通常取值3、5或10。
本例中cv=3，表示将数据集分为3份进行交叉验证，其返回值为3次评估的成绩
2. 本例中cv=3，表示将数据集分为3份进行交叉验证，其返回值为3次评估的成绩。

步骤2、使用留一法（leave-one-out）交叉验证评估模型

```
from sklearn.datasets import load_iris
from sklearn.model_selection import LeaveOneOut, cross_val_score
from sklearn.neighbors import KNeighborsClassifier

iris = load_iris() # 加载数据集
model = KNeighborsClassifier() # 创建模型

loo = LeaveOneOut() # 定义留一法策略，作为cv参数的值
scores = cross_val_score(model, iris.data, iris.target, cv=loo)

print(len(scores)) # 留一法输出150个评估成绩（因为样本数为150）
print(scores.mean()) # 计算平均成绩
```

输出结果：

```
150
0.9666666666666667
```

说明：

1、留一法交叉验证可以看作是极端情况下的k-折交叉验证。每次选1个样本做测试集、其他样本做训练集进行评估，有多少样本就会评估多少次。

2、本例中样本数为150，因此交叉验证返回150个结果。

步骤3、使用打乱划分 (shuffle-split) 交叉验证评估模型

```
from sklearn.datasets import load_iris
from sklearn.model_selection import ShuffleSplit, cross_val_score
from sklearn.linear_model import LogisticRegression

iris = load_iris()
model = LogisticRegression()

# 划分5次，每次取100个样本作为训练集，10个样本作为测试集
shuffle_split = ShuffleSplit(train_size=100, test_size=10, n_splits=5)
scores = cross_val_score(model, iris.data, iris.target, cv=shuffle_split)
print(scores)
print(scores.mean())

# 除指定样本个数外，还可以指定百分比
# 这里就是划分5次，每次取80%为训练集，20%为测试集
shuffle_split = ShuffleSplit(train_size=0.8, test_size=0.2, n_splits=5)
```

输出结果：

```
[1.  1.  1.  1.  1.]
1.0
```

说明：

1. 该方法可以同时指定划分次数和训练集与测试集大小。
2. 参数说明：
 - n_splits 划分次数
 - train_size 训练集样本数量或比例
 - Test_size 测试集样本数量或比例
3. 该方法允许只取部分样本参与训练和评估，因此适用于比较大的数据集。

六 任务总结

常用交叉验证方法有：k-折交叉验证 (k-fold)、留一法交叉验证 (leave-one-out)、打乱划分交叉验证 (shuffle-split) 等

- k折交叉验证: 是应用最多的交叉验证方法，使用不重复采样，优点是每个样本只会在训练集或测试集中出现一次，所有数据都会参与到训练和预测中，有效避免过拟合，充分体现了交叉的思想。
- 留一法优点：每一回合中几乎所有的样本皆用于训练模型，因此最接近原始样本的分布，这样评估所得的结果比较可靠，缺点：计算成本高，因为需要建立的模型数量和原始数据集样本数量一致，尤其当样本数量很大的时候。可以考虑并行化训练模型减少训练时间。
- 打乱(shuffle): 因为原本的数据集有可能是有序的，如果正例集中在前面，负例集中在后面，那么便会导致验证集或测试集会出现大部分是负例的情况。很有可能导致负例训练效果不佳，模型整体性

能变差。此外，就算不是有序的，打乱也会显得更为“公平”，也给模型提升多一份机会。(即随机划分出的某个数据集可能更能代表整体数据(包括未收集到的数据))。

七 任务知识测试

- 1、scikit-learn中，交叉验证函数为：（单选）（ ）
 - A、train_test_split
 - B、score
 - C、cross_val_score
 - D、adjusted_rand_score
- 2、下列哪一种交叉验证方法评估次数与样本个数相同？（单选）（ ）
 - A、k-折交叉验证
 - B、留一法交叉验证
 - C、打乱划分交叉验证
- 3、交叉验证的核心思想是：（单选）（ ）
 - A、将数据集多次划分
 - B、减少验证评估次数
 - C、减少模型创建数量
- 4、下列选项，属于交叉验证的优点的有：（多选）（ ）
 - A、更加客观全面的评估模型性能
 - B、降低单次划分数据集对模型造成的随机影响
 - C、提高数据的使用效率
 - D、降低模型评估的计算复杂度