

绘制ROC曲线及P-R曲线

一、任务描述

ROC曲线 (Receiver Operating Characteristic Curve) 以假正率 (FPR) 为X轴、真正率 (TPR) 为y轴。曲线越靠左上方说明模型性能越好, 反之越差。ROC曲线下方的面积叫做AUC(曲线下面积), 其值越大模型性能越好。P-R曲线 (精确率-召回率曲线) 以召回率(Recall)为X轴, 精确率(Precision)为y轴, 直观反映二者的关系。两种曲线都是分类模型常用的可视化评估工具。

本任务使用乳腺癌数据集 (breast_cancer), 主要实践内容:

- 1、基于支持向量机 (SVM) 建立肿瘤预测模型, 并绘制ROC曲线。
- 2、基于逻辑回归建模, 并绘制PR曲线。

二、任务目标

- 握ROC曲线的绘制、掌握AUC面积的计算方法
- 掌握P-R曲线的绘制

三、任务环境

- 操作系统: Windows10、Ubuntu18.04
- 工具软件: Anaconda3 2019、Python3.7
- 硬件环境: 无特殊要求
- 依赖库列表

```
matplotlib    3.3.4
numpy          1.19.5
scikit-learn   0.24.2
```

四、任务分析

本任务涉及以下环节:

- 1) 分别使用支持向量机和逻辑回归建立肿瘤预测模型
- 2) 绘制ROC曲线, 计算AUC面积
- 3) 绘制P-R曲线

五、任务实施

步骤1、加载、拆分breast_cancer数据集

```
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
import numpy as np

# 加载breast_cancer数据集
cancer = load_breast_cancer()

# 拆分数据集
X_train, X_test, y_train, y_test = train_test_split(cancer.data, cancer.target,
                                                    random_state=0)
```

步骤2、建立SVM分类模型，绘制ROC曲线


```
from sklearn.svm import SVC
from sklearn.metrics import roc_curve, auc

model = SVC(gamma='scale').fit(X_train, y_train) # 创建SVC模型，拟合训练数据

y_score = model.decision_function(X_test) # 计算样本点到分割面的函数距离
fpr, tpr, threshold = roc_curve(y_test, y_score) # 计算假正率、真正率、阈值
auc2 = auc(fpr, tpr) # 计算auc面积，auc值越接近1模型性能越好
# 绘制ROC曲线
plt.title('ROC Curve') # 标题
plt.xlabel('FPR', fontsize=14) # x轴标签
plt.ylabel('TPR', fontsize=14) # y轴标签
plt.plot(fpr, tpr, label='AUC = %0.4f'%auc2, c='r') # 划线
plt.legend(fontsize=12) # 图例

plt.show()
```

输出结果:



说明:

- 1、ROC曲线越靠近左上角，模型性能越好，相应的，AUC面积越大则模型性能越好。
- 2、在同一数据集上不同分类模型的ROC曲线，如果一个模型的ROC曲线可以将另一个包住，则前者性能更好。

步骤3、不同模型的ROC曲线比较（选做）


- 使用不同的参数定义三个模型，比较其ROC曲线
- ROC曲线越靠近左上角（auc面积越大），模型性能越好

```
model_1 = SVC(gamma='scale').fit(X_train, y_train) # 创建SVC模型，拟合训练数据
model_2 = SVC().fit(X_train, y_train)
model_3 = SVC(kernel='linear').fit(X_train, y_train)
models = [model_1, model_2, model_3]

# 绘制ROC曲线
plt.title('ROC Curve') # 标题
for m in models:
    y_score = m.decision_function(X_test) # 计算样本点到分割面的函数距离
    fpr, tpr, threshold = roc_curve(y_test, y_score) # 计算假正率、真正率、阈值
    plt.xlabel('FPR', fontsize=14) # x轴标签
    plt.ylabel('TPR', fontsize=14) # y轴标签
    plt.plot(fpr, tpr, label='AUC=%0.4f'%auc(fpr, tpr)) # 划线

plt.legend(fontsize=12) # 图例
plt.show()
```

输出结果：



步骤4、绘制P-R曲线（精确率-召回率曲线）

P-R曲线（精确率-召回率曲线）以召回率（Recall）为X轴，精确率（Precision）为y轴，直观反映二者间的关系。

- P-R曲线反映了精确率和召回率之间的关系
- P-R曲线越凸向右上方，表示模型性能越好

```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import precision_recall_curve # P-R曲线计算函数
```


```
model = LogisticRegression().fit(X_train, y_train) # 创建LR模型，拟合训练数据

y_score = model.decision_function(X_test) # 计算样本点到分割面的函数距离

# PR曲线计算函数（返回值为精确率、召回率、阈值，参数为测试集和上述距离）
precisions, recalls, thresholds = precision_recall_curve(y_test, y_score)

plt.title('P-R Curve') # 标题
plt.xlabel('Recalls', fontsize=14) # x轴标签
plt.ylabel('Precisions', fontsize=14) # y轴标签
plt.plot(recalls, precisions) # 画线
plt.show()
```

输出结果：



说明：

- 1、模型的精确度和召回率互相制约，P-R曲线越向右上凸，表示模型性能越好。
- 2、在正负样本数量均衡的情况下，P-R曲线和ROC曲线的趋势差不多，但由于精确率和召回率更关注正样本的情况，当负样本比较多时P-R曲线的反映效果一般，此时使用ROC曲线更合适。

六、任务总结

- ROC曲线以假正率（FPR）和真正率（TPR）为X轴和y轴。
- TPR(True Positive Rate): 真正率(灵敏度)，越大越好，1为理想状态。计算公式： $TPR = TP / (TP + FN)$ 。
- FPR(False Positive Rate): 假正率(特异度)，越小越好，0为理想状态。计算公式： $FPR = FP / (FP + TN)$ 。
- ROC曲线下方的面积叫做AUC(Area Under Curve-曲线下面积)，其值越大模型性能越好。

七、知识测试

1、下列关于ROC曲线，描述正确的是：（多选）（ ）

- A、以准确率和召回率为坐标轴
- B、以假正率和真正率为坐标轴
- C、曲线越靠近左上角，模型性能越好

D、曲线越靠近右上角，模型性能越好

2、P-R曲线关注的指标是：（多选）（ ）

A、准确率

B、精确率

C、召回率

3、下列关于AUC指标的说法，正确的是：（多选）（ ）

A、ROC曲线的下面积

B、PR曲线的下面积

C、使用auc函数来计算

D、值越大模型越准确

4、当样本不平衡时，哪个指标更合适？（单选）（ ）

A、P-R曲线

B、ROC曲线